

Практическая работа 2.

SVD и PCA: спектральный анализ матрицы данных, тензоры и снижение размерности

Цель

Научиться применять сингулярное разложение (SVD) к матрице данных, использовать его для реализации метода главных компонент (PCA), оценивать потери информации при снижении размерности и связывать результаты с устойчивостью линейных моделей и тензорным представлением данных.

Компетенции

MF-5. Дополнительные главы математической теории ИИ.

Способен применять продвинутое математические методы (теория графов, функциональный анализ, топология, теория категорий) для решения сложных задач искусственного интеллекта и разработки новых алгоритмов.

Индикаторы

MF-5.1. Применяет современную теоретическую математику для разработки новых алгоритмов и формулирования перспективных задач ИИ.

Разрабатывает алгоритмы ИИ с использованием современных математических методов, применяет их для исследования сходимости алгоритмов обучения и анализа структуры данных (в том числе с использованием топологических и геометрических подходов).

Необходимые ресурсы

- компьютер с установленным Python и Jupyter Notebook;
- доступ к учебному git-репозиторию (GitHub, GitLab или внутренний сервер);
- методические материалы по матричному анализу (учебники, конспект, презентация).

Правила оформления

- работа выполняется в одном Jupyter Notebook (`fam_fa_practice1.ipynb`);
- ноутбук должен содержать:
 - краткое текстовое описание цели и выводов (markdown-ячейки);
 - реализацию вычислений и проверок (code-ячейки);
 - при необходимости графики и таблицы для иллюстрации.
- в начале файла указываются: ФИО, группа, дата, название работы;
- по завершении работы студент делает `commit` и `push` ноутбука в репозиторий в директорию `functional_analysis/practice1/ФИО`;
- при необходимости добавляется краткий `README.md` (1–2 абзаца о содержании работы).

Задания

Задание 1. Подготовка данных и сингулярное разложение

1. Загрузите или задайте матрицу данных X , где строки соответствуют объектам, а столбцы — числовым признакам.
2. Выполните предварительную обработку:
 - вычтите среднее значение из каждого столбца (центрирование);
 - при необходимости выполните нормировку признаков.
3. Найдите сингулярное разложение

$$X = U\Sigma V^\top.$$

4. В текстовом комментарии поясните:
 - роль матриц U , V и диагональной матрицы Σ ;
 - как сингулярные значения связаны с «силой» латентных факторов и вкладом в объяснение вариации данных.

Задание 2. Реализация PCA через SVD

1. Реализуйте метод главных компонент (PCA), используя матрицу V и сингулярные значения:
 - получите координаты объектов в пространстве главных компонент;
 - постройте проекцию данных на первые две-три компоненты.
2. Выберите число компонент k (например, по доле объяснённой дисперсии) и постройте низкоранговую аппроксимацию

$$X_k = U_k \Sigma_k V_k^\top.$$

3. Вычислите погрешность аппроксимации, например норму Фробениуса:

$$\|X - X_k\|_F$$

и обсудите, насколько выбранный k достаточен для сохранения информации.

Задание 3. Визуализация и интерпретация

1. Отобразите объекты в координатах первых двух главных компонент на плоскости (график рассеяния).
2. Если для данных известны классы или категории, отметьте их различными цветами и обсудите:
 - видны ли кластеры или разделимость классов;
 - помогает ли снижение размерности в интерпретации структуры данных.
3. В текстовом комментарии свяжите снижение размерности с устойчивостью моделей и подавлением шума.

Задание 4. Связь с линейной регрессией (необязательное)

1. Постройте простую линейную модель (регрессию или классификатор) на исходных признаках.
2. Постройте аналогичную модель на признаках после PCA (на первых k компонентах).
3. Сравните качество и устойчивость решения (например, на кросс-валидации или при добавлении шума к данным) и сформулируйте вывод о влиянии снижения размерности.

Задание 5. Тензорное представление изображений и батчей

1. Задайте пример данных для задач компьютерного зрения:
 - одно цветное изображение как трёхмерный массив (тензор) формы (C, H, W) , где C — число каналов, H и W — высота и ширина;
 - батч из B изображений как четырёхмерный массив формы (B, C, H, W) .
2. В текстовом комментарии поясните:
 - какие оси тензора соответствуют объектам, каналам, высоте и ширине;
 - чем такое представление отличается от хранения тех же данных в виде одной «плоской» матрицы.

Задание 6. Связь тензоров и матриц через развёртки

1. Для тензора формы (B, C, H, W) выполните развёртку (reshape) в матрицу:
 - вариант 1: матрица признаков объектов формы $(B, C \cdot H \cdot W)$;
 - вариант 2: матрица пикселей формы $(C \cdot H \cdot W, B)$.
2. Для каждой матрицы:
 - оцените её ранг (например, через SVD);
 - кратко обсудите, что ранг говорит о количестве независимых признаков и возможной избыточности описания.

Задание 7. SVD и PCA для тензорных данных

1. Используя матрицу признаков формы $(B, C \cdot H \cdot W)$, выполните SVD и реализуйте PCA:
 - снизьте размерность признаков до k главных компонент;
 - восстановите приближённые изображения из пониженного пространства.
2. Оцените качество восстановления, например, с помощью нормы Фробениуса разности между исходным и восстановленным батчем.
3. В текстовом комментарии обсудите:
 - какие детали изображений теряются при малом k ;
 - как это связано с низкоранговой аппроксимацией тензора данных.

Задание 8. Тензорное произведение признаков

1. Рассмотрите два вектора признаков для объекта:

$$x \in \mathbb{R}^m, \quad z \in \mathbb{R}^n.$$

2. Постройте тензорное произведение $x \otimes z$ в виде матрицы формы (m, n) , где

$$(x \otimes z)_{ij} = x_i z_j.$$

3. В текстовом комментарии интерпретируйте элементы матрицы $x \otimes z$ как признаки взаимодействия компонентов x и z (например, для полиномиальных моделей).
4. Объясните, как такие взаимодействия могут использоваться в моделях искусственного интеллекта и почему тензорное представление удобно для описания расширенных признаков пространств.

Критерии оценки (100-бальная система)

Корректность вычисления SVD и реализации PCA (включая работу с тензорами и развёртками) — 40 баллов.

Оценка потерь информации и интерпретация результатов — 30 баллов. Главные компоненты, низкоранговая аппроксимация, тензорное представление. Сравнение моделей до и после PCA, анализ устойчивости, нестандартные тензорные примеры

Качество оформления ноутбука и размещения в git — 20 баллов. Структурированность (разделы, заголовки, пояснения), аккуратный код; корректный `commit` и `push` в нужную директорию.

Самостоятельность и глубина выводов — 10 баллов. Наличие собственных примеров и комментариев; попытка связать результаты с другими курсами ИИ (оптимизация, методы машинного обучения).

Порог зачёта по работе: **60 баллов.**