

Дисциплина: Математические основы искусственного интеллекта

Модуль: Матричный анализ

Компетенция: MF-5 — способен применять продвинутые математические методы для решения сложных задач ИИ и разработки новых алгоритмов.

Матричный анализ

1. Матрица данных в задачах ИИ обычно трактуется как
 - (a) строки — признаки, столбцы — объекты
 - (b) строки — объекты, столбцы — признаки
 - (c) квадратная матрица операторов
 - (d) диагональная матрица весов
2. Ранг матрицы A — это
 - (a) число ненулевых элементов матрицы
 - (b) число строк матрицы
 - (c) максимальное число линейно независимых строк или столбцов
 - (d) число собственных значений
3. Образ линейного оператора $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ — это
 - (a) множество всех входных векторов
 - (b) линейная оболочка столбцов матрицы A
 - (c) множество всех решений уравнения $Ax = 0$
 - (d) ядро оператора
4. Ядро линейного оператора $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ — это
 - (a) линейная оболочка строк матрицы A
 - (b) множество всех x , для которых $Ax = 0$
 - (c) множество всех y , которые представимы как Ax
 - (d) множество всех собственных векторов
5. Какое утверждение верно для матрицы данных X в контексте линейной регрессии?
 - (a) Столбцы X всегда линейно независимы
 - (b) Пространство столбцов X определяет множество возможных линейных комбинаций признаков
 - (c) Ранг X не влияет на устойчивость решения
 - (d) Ядро X не связано с переобучением

6. Собственное значение λ матрицы $A \in \mathbb{R}^{n \times n}$ — это число, для которого

- (a) существует ненулевой вектор x с $Ax = \lambda x$
- (b) $Ax = 0$ для всех x
- (c) $\det(A - \lambda I) = 0$ только при $\lambda = 0$
- (d) λ всегда равно рангу матрицы

7. Сингулярное разложение (SVD) матрицы $A \in \mathbb{R}^{m \times n}$ имеет вид

- (a) $A = Q\Lambda Q^{-1}$
- (b) $A = U\Sigma V^T$
- (c) $A = PDP^{-1}$
- (d) $A = LU$

8. Матрицы U и V в SVD $A = U\Sigma V^T$ обладают свойством

- (a) диагональности
- (b) ортогональности (ортонормированные столбцы)
- (c) верхнетреугольности
- (d) симметричности

9. Диагональная матрица Σ в SVD содержит

- (a) собственные значения A
- (b) сингулярные значения — квадратные корни из собственных значений $A^T A$
- (c) значения ранга матрицы
- (d) коэффициенты линейной регрессии

10. Псевдообратная матрица A^+ (Мура-Пенроуза) для $A \in \mathbb{R}^{m \times n}$ с SVD $A = U\Sigma V^T$ равна

- (a) $A^+ = A^{-1}$
- (b) $A^+ = V\Sigma^{-1}U^T$
- (c) $A^+ = U\Sigma^{-1}V^T$
- (d) $A^+ = A^T$

11. Какое утверждение верно для псевдообратной матрицы A^+ ?

- (a) Существует только для квадратных матриц
- (b) Используется для решения недоопределённых и переопределённых систем в смысле наименьших квадратов
- (c) Всегда совпадает с транспонированной матрицей
- (d) Не используется в ИИ

12. Если A имеет полный столбцовый ранг, то решение $x = A^+b$

- (a) совпадает с точным решением $Ax = b$ для любого b

- (b) даёт одно из решений, но не обязательно наименьших квадратов
- (c) совпадает с решением задачи наименьших квадратов для переопределённой системы $Ax \approx b$
- (d) всегда минимизирует $\|x\|_\infty$, но не $\|Ax - b\|$

13. Главные компоненты (PCA) в матричном виде обычно определяются как

- (a) собственные векторы матрицы X
- (b) столбцы U или V в SVD матрицы центрированных данных
- (c) строки матрицы X
- (d) решения системы нормальных уравнений

14. Какой шаг обычно выполняется перед применением PCA к матрице данных X ?

- (a) Умножение всех признаков на случайный коэффициент
- (b) Центрирование данных (вычитание среднего по столбцам)
- (c) Сортировка строк по возрастанию
- (d) Удаление всех нулевых столбцов

15. Снижение размерности с помощью PCA заключается в

- (a) удалении всех признаков
- (b) замене матрицы X её псевдообратной
- (c) проекции данных на подпространство, натянутое на первые k главные компоненты
- (d) решении системы нормальных уравнений

16. Связь SVD и PCA:

- (a) SVD не используется для PCA
- (b) PCA можно реализовать через SVD центрированной матрицы данных
- (c) PCA — это спектральное разложение графа, а не матрицы данных
- (d) SVD применим только к квадратным матрицам, поэтому не подходит для PCA

17. В матричной форме линейная регрессия записывается как

- (a) $y = Ax + \varepsilon$
- (b) $y = Xw + \varepsilon$
- (c) $X = yw + \varepsilon$
- (d) $w = Xy + \varepsilon$

18. Метод наименьших квадратов (МНК) для линейной регрессии соответствует

- (a) минимизации $\|w\|$
- (b) решению $Xw = y$ точным образом
- (c) минимизации $\|Xw - y\|_2^2$ по w
- (d) минимизации числа признаков

19. Нормальные уравнения для МНК-регрессии $y = Xw + \varepsilon$ имеют вид

- (a) $Xy = w$
- (b) $X^\top Xw = X^\top y$
- (c) $XX^\top w = y$
- (d) $X^\top y = y$

20. При условии, что $X^\top X$ обратима, решение нормальных уравнений равно

- (a) $w = (X^\top X)^{-1}y$
- (b) $w = X^\top y$
- (c) $w = (X^\top X)^{-1}X^\top y$
- (d) $w = Xy$

21. Связь МНК и псевдообратной матрицы:

- (a) Решение МНК всегда записывается как $w = X^\top y$
- (b) Решение МНК можно записать как $w = X^+ y$
- (c) Псевдообратная матрица не применяется в регрессии
- (d) МНК и псевдообратная матрица — независимые понятия

22. Вектор предсказаний $\hat{y} = Xw^*$ (где w^* — МНК-решение) можно интерпретировать как

- (a) произвольную линейную комбинацию столбцов X
- (b) ортогональную проекцию y на подпространство столбцов матрицы X
- (c) ортогональную проекцию y на ядро X
- (d) проекцию на пространство строк матрицы X

23. Какое утверждение верно про вектор ошибки $\varepsilon = y - \hat{y}$ при МНК-решении?

- (a) Он параллелен столбцам матрицы X
- (b) Он ортогонален каждому столбцу матрицы X
- (c) Он равен нулю
- (d) Он всегда имеет минимальную ℓ_∞ -норму

24. Малые сингулярные значения матрицы данных X при решении задач регрессии обычно означают

- (a) хорошую обусловленность задачи
- (b) возможную неустойчивость решения (чувствительность к шуму и регуляризации)
- (c) отсутствие переобучения
- (d) отсутствие линейной зависимости между признаками

25. Регуляризация (например, ридж-регрессия) в матричной форме может быть интерпретирована как

- (a) добавление к функционалу потерь штрафа по норме параметров, что изменяет матрицу нормальных уравнений на $X^T X + \lambda I$
- (b) замена матрицы данных на её псевдообратную
- (c) удаление всех малых сингулярных значений из SVD
- (d) умножение вектора y на константу

26. Тензорное произведение двух векторных пространств V и W обозначается

- (a) $V \oplus W$
- (b) $V \otimes W$
- (c) VW
- (d) $V \times W$

27. Тензорное произведение векторов $v \in V$ и $w \in W$ обозначается и интерпретируется как

- (a) $v + w$ — сумма векторов
- (b) vw — покомпонентное произведение
- (c) $v \otimes w$ — ранговый-1 тензор, задающий билинейную форму на $V^* \times W^*$
- (d) $v \cdot w$ — скалярное произведение

28. Какое утверждение верно для тензорного произведения пространств $\mathbb{R}^m$ и $\mathbb{R}^n$?

- (a) $\mathbb{R}^m \otimes \mathbb{R}^n$ изоморфно $\mathbb{R}^{m+n}$
- (b) $\mathbb{R}^m \otimes \mathbb{R}^n$ изоморфно $\mathbb{R}^{mn}$
- (c) $\mathbb{R}^m \otimes \mathbb{R}^n$ не является линейным пространством
- (d) $\mathbb{R}^m \otimes \mathbb{R}^n$ всегда одномерно

- 29.** В контексте ИИ тензоры чаще всего используются для
- (a) представления сложных структур данных (изображения, видео, батчи) как многомерных массивов
 - (b) только для записи скалярных произведений
 - (c) только в теории графов
 - (d) исключительно в теории множеств
- 30.** Какое из утверждений корректно описывает связь тензоров и матричного анализа в задачах ИИ?
- (a) Тензоры и матрицы — независимые понятия, не пересекающиеся в приложениях
 - (b) Тензор можно рассматривать как многомерное обобщение матрицы, а тензорное произведение — как обобщение матричного произведения
 - (c) Матрицы — частный случай тензоров только в бесконечномерных пространствах
 - (d) Тензоры используются только в общей теории относительности, но не в ИИ
-

Ключ к тесту

- 1: b
- 2: c
- 3: b
- 4: b
- 5: b
- 6: a
- 7: b
- 8: b
- 9: b
- 10: b
- 11: b
- 12: c
- 13: b
- 14: b
- 15: c
- 16: b
- 17: b
- 18: c
- 19: b

20: c
21: b
22: b
23: b
24: b
25: a
26: b
27: c
28: b
29: a
30: b