

Проектное задание №1

Оптимизация отбора признаков

1. Ознакомьтесь с демонстрационной версией блокнота и прилагаемым набором данных
2. Подготовьте программу для обучения модели-классификатора. Выбор модели выбирается – это остаток деления вашего ИСУ на 4
 - 0) Логическая регрессия
 - 1) Алгоритм случайного леса
 - 2) Метод опорных векторов
 - 3) Градиентный бустинг
3. Выберите не менее 3-х гиперпараметров модели, настройка которых вносит основной вклад в метрики качества классификации (ориентируйтесь на F-score)
4. Обучите и протестируйте модель-классификатор с настройкой выбранных гиперпараметров при помощи библиотеки Optuna; зафиксируйте результаты (метрики и приближение к оптимальным параметрам)
5. Рассмотрите отображение исходного пространства в пространство главных компонент при помощи инструмента KernelPCA (ядро rbf)
6. Проверьте качество классификации в новом признаковом пространстве при настройках модели по п.3.
7. Проанализируйте спектр матрицы-отображения – распределение сингулярных чисел для 3-х классов объектов из набора данных
8. Предложите и реализуйте схему отбора признаков для обучения модели на основе результатов анализа спектра. Определите, возможно ли улучшить качество классификации на тестовой выборке путем отбора признаков, основанного на анализе спектра матриц признаков для классов объектов. Результаты зафиксируйте, проиллюстрируйте и прокомментируйте

Подсказка: при анализе спектра, возможно, следует обратить внимание сперва на различия сингулярных чисел матриц признаков для объектов различных классов

8*. Приведите обоснование, на каком этапе подготовки данных следует выполнить отображение KernelPCA. Как этот выбор связан с возможной утечкой данных DataLeak и насколько это критично? Приведите развернутое теоретическое обоснование